

卒業論文

機械学習を用いた宇宙線電子スペクトルにおける近
傍超新星残骸の兆候の識別および分類

早稲田大学

先進理工学部 物理学科

平本亮

Motz Holger Martin 研究室

2026 年 1 月 26 日

概要

宇宙から飛来する高エネルギー荷電粒子である宇宙線は、1912年にHess[1]によって発見されて以来、現在までにその様々な性質が研究されてきた。特にその起源や加速機構についての研究が盛んに行われている。一方で宇宙線の荷電性と銀河内磁場による影響で、宇宙線の銀河内の伝搬は拡散的であり、その到来方向からの起源の特定については現在でも難点となっている。

飛来する宇宙線の主成分は陽子であり、続いてヘリウムなどの原子核や電子、陽電子が占める。宇宙線の持つエネルギーは非常に多様であり、数 MeV から数億 TeV までに至る宇宙線が観測されている。中でも宇宙線電子は 2026 年現在で TeV 領域まで観測されている。宇宙線の起源の一つに超新星残骸 (Super Nova Remnant:SNR) があり、超新星爆発によって生じた衝撃波によって宇宙線が加速されると考えられている。一方で、宇宙線電子は質量が小さく、シンクロトロン放射や逆コンプトン散乱によるエネルギー損失が大きいので、伝播する距離が制限される。特に TeV 領域の宇宙線電子はその伝播距離が $\lesssim 1\text{kpc}$ に制限されるため、その起源は近傍の超新星残骸であると考えられている [2]。

宇宙線電子の観測は Fermi-LAT、AMS-02、DAMPE、CALET などの衛星実験や H.E.S.S.、VERITAS などの地上観測実験によって行われてきた。特に CALET は 2015 年から国際宇宙ステーション (International Space Station:ISS) に搭載されて観測を行っており、7.5TeV までの宇宙線電子スペクトルの測定が報告されている [3]。現在も 20TeV までの観測を目指して稼働中である。これらの宇宙線電子観測実験によって、宇宙線電子スペクトルのべき乗則分布や 1TeV 付近でのスペクトルの折れ曲がり、べき指数の変化が観測されている [3]。このスペクトルのブレイクは遠い超新星残骸からの寄与であると言われている。また、CALET の観測では 4~5TeV 付近でスペクトルの硬化のようなものが見えており、近傍の超新星残骸からの寄与がある可能性が示唆されている。特にこの TeV 領域では、3 つの近傍超新星残骸 (Vela SNR, Cygnus Loop, Monogem) からの寄与が期待されている。一方で、10TeV を超える宇宙線電子の観測の結果はまだ報告されておらず、さらに現在報告されている高エネルギー領域の観測では、その統計量の少なさから統計誤差が大きく、bin によるフィッティングスペクトルの特徴から近傍超新星残骸の寄与を確定することは難しい。

本研究では近年注目を集めている機械学習を解析に取り入れることで、スペクトルフィッティングによる解析に頼らず CALET による観測データから直接的に近傍超新星残骸による寄与の特徴を捉えることを目標とする。機械学習では観測で得られる宇宙線電子のヒットデータの特徴を学習させ、近傍超新星残骸の寄与の有無や超新星残骸のカットオフエネルギーなどの特徴を捉えられるかどうかを検証する。学習には CALET による観測を再現した宇宙線電子のモンテカルロシミュレーションデータを用いる。モンテカルロシミュレーションには、宇宙線の伝搬を数値的に計算する DRAGON コード [4] で得られたフラックスを観測データへフィッティングして得られた理論的なスペクトルを使用する。

学習モデルは全結合層を用いたニューラルネットワークと、畳み込みニューラルネットワークを基調としたモデルを構築した。学習の結果、超新星残骸の有無の識別を約 85% の精度で、超新星残骸の特徴を示すカットオフエネルギーの予測については、10TeV または 100TeV の二値分解タスクにおいては約 91% の精度で行うことが確認できた。

今後の課題としては、学習データの見直し、モデルの見直し、およびハイパーパラメータの走査によるさらなる最適化が挙げられる。また、超新星残骸の特徴の分類では、カットオフエネルギー以外の特徴を捉えられるかを検討する必要がある。さらに、カットオフエネルギーの連続的な値での予測を行うモデルの構築が求められる。加えて、実際の観測データへの適応も求められる。

目次

1	序章	4
1.1	宇宙線	4
1.2	研究背景	4
1.3	研究目的	4
2	CALET	5
3	宇宙線電子	7
3.1	加速機構	7
3.2	伝播機構	8
3.3	宇宙線電子のスペクトル	9
4	機械学習	11
4.1	機械学習の仕組み	11
4.2	機械学習の構造	11
4.3	深層学習	13
4.4	損失関数と最適化	13
4.5	機械学習モデル構造	14
5	機械学習に使用するデータと観測サンプル	17
5.1	観測サンプルの作成	17
5.2	機械学習用データセットの作成	18
6	機械学習モデルの作成	20
6.1	タスク 1: 近傍超新星残骸の兆候の識別	20
6.2	タスク 2: 超新星残骸のカットオフエネルギー E_c の分類	23
7	学習の結果と評価	25
7.1	タスク 1: 近傍超新星残骸の兆候の識別	25
7.2	タスク 2: 超新星残骸のカットオフエネルギー E_c の分類	28
8	まとめと今後の展望	31
8.1	まとめ	31
8.2	今後の展望	31
9	謝辞	33
	参考文献	34
A	機械学習で用いた関数	36

図目次

2.1	CALET の外観 [5]	5
2.2	CALET の模式図 [6]	6
2.3	宇宙線電子スペクトルの測定結果 [3]。赤色のプロットが CALET での観測結果を示している。	6
3.1	衝撃波加速の模式図	7
3.2	近傍超新星残骸の寄与を考慮したフィッティング [3]	9
4.1	機械学習の流れ	11
4.2	全結合層によるネットワーク構造の例	12
4.3	深層学習におけるニューラルネットワークの構造	13
4.4	残差接続ネットワークの構造	15
4.5	畳み込みニューラルネットワークにおける畳み込み演算	15
5.1	学習およびテストデータの構造	19
6.1	エネルギーの到来方向マップの例 (Vela SNR ありの場合)。エネルギーは対数スケールで表示してあり、単位は GeV である。全天を Mollweide 投影で表示している。	21
6.2	入力画像データの例 (Vela SNR ありの場合)	21
6.3	タスク 1 で作成した学習モデル	22
6.4	$E_c=10$ TeV のときのスペクトルフィッティングの結果	23
6.5	$E_c=100$ TeV のときのスペクトルフィッティングの結果	23
6.6	タスク 2 で作成した学習モデル	24
7.1	タスク 1 の学習結果 ($E_c=10$ TeV)	25
7.2	タスク 1 の学習結果 ($E_c=20$ TeV)	26
7.3	タスク 1 の学習結果 ($E_c=50$ TeV)	26
7.4	タスク 1 の学習結果 ($E_c=100$ TeV)	27
7.5	タスク 2 の学習結果	28

表目次

5.1	使用したモデルの各パラメータとその値 [7]	17
5.2	近傍超新星残骸の年齢、太陽系からの距離、銀河座標での緯度と経度	18
5.3	サンプル群 A における各パラメータの設定	18
5.4	サンプル群 B における各パラメータの設定	18
6.1	タスク 1 で設定した SNR パラメータ	22
6.2	タスク 1 で設定した ML パラメータ	22
6.3	タスク 2 で設定した SNR パラメータ	24
6.4	タスク 2 で設定した ML パラメータ	24
7.1	タスク 1 における各カットオフエネルギーでの最良結果	27
7.2	タスク 2 における最も良い結果	29
7.3	各入力データ数 l における最小エネルギーデータの平均値	29

1 序章

1.1 宇宙線

宇宙線とは、宇宙から飛来する高エネルギーの荷電粒子のことである。現在では宇宙線の定義は広く、宇宙線と呼ばれるものの中には高エネルギー γ 線のような電磁波やニュートリノのような中性粒子も含まれるが、本稿、は原点に立ち返って高エネルギー荷電粒子のことを指すこととする。宇宙線のうち、9 割は陽子であり、約 1 割はヘリウム原子核、その他の重い原子核や電子などが残りの割合を占める。宇宙線のエネルギーは非常に広範囲にわたり、数 MeV から 10^{20} eV を超えるものまで観測されている。宇宙線はシンクロトン放射や逆コンプトン散乱によってエネルギー損失が生じ、エネルギースペクトルはべき乗則に従って減少する。宇宙線のエネルギースペクトルは現在までに観測された宇宙線のうち、最も高いエネルギーを持つものは 1991 年に観測された 3.2×10^{20} eV の宇宙線 [8] である。

宇宙線のような荷電粒子は銀河内を伝播するときに銀河磁場によって進行方向が曲げられ、拡散的に運動する。そのため、宇宙線の到来方向を観測しても起源を特定できないことが多い。故に宇宙線の起源や加速機構については、候補はあるものの未だ説明されていないことも多い。

1.2 研究背景

宇宙線電子の起源の有力な候補は近傍の超新星残骸 (Super Nova Remnant: SNR) であるが、その確定的な寄与の特徴は未だエネルギースペクトルの中に現れていない。CALET などの衛星実験による宇宙線電子スペクトルの観測では、4~5 TeV 付近で Vela SNR やその他近傍の超新星残骸の寄与を示唆するスペクトルの硬化のようなものが見えるが、高エネルギー領域の観測数の少なさゆえの統計誤差の大きさから、この寄与を確定することは現段階では難しい。したがって、さらなる観測時間の確保や、寄与を識別するためのスペクトルフィッティングに頼らない新たな解析方法の開発が求められている。

1.3 研究目的

本研究では近年注目を集めている機械学習による解析を新たな手法として取り入れ、2030 年までの CALET での観測を想定した宇宙線電子のヒットデータから直接的に近傍超新星残骸の寄与を識別・分類できるかどうかを検証することを目的とする。超新星残骸の寄与を想定し、DRAGON コード [4] を用いた数値シミュレーションや、スペクトルフィッティング、異方性の計算や観測条件から確率的にモンテカルロシミュレーションで生成された、エネルギーや到来方向のデータからその特徴を機械学習で学習させ、超新星残骸の寄与の有無やカットオフエネルギーなどの超新星残骸の特徴を予測することを目標とする。

2 CALET

現在まで、様々な観測によって宇宙線電子の測定が行われてきた。H.E.S.S.(2004～)などの地上観測実験、Fermi-LAT(2008～)、AMS-02(2011～)、DAMPE(2015～)、CALET(2015～)などの衛星実験などによって、宇宙線電子スペクトルが測定されている。




図 2.1 CALET の外観 [5]

CALET(CALorimetric Electron Telescope) は、国際宇宙ステーション (International Space Station:ISS) に搭載されている宇宙線検出用のカロリメータ検出器である。CALET は日本の宇宙航空研究開発機構 (Japan Aerospace Exploration Agency:JAXA)、イタリアの宇宙機関 (Italian Space Agency:ASI)、アメリカの航空宇宙局 (National Aeronautics and Space Administration:NASA) が共同で開発した。図 2.1 に示すように、CALET は ISS の日本実験棟「きぼう」の外部搭載型プラットフォームに設置されている。CALET は 2015 年に打ち上げられ、その年の 10 月から運用を開始し、現在も観測が続けられている。現在は、2030 年までの約 14 年間の観測が決まっている。




図 2.2 CALET の模式図 [6]

図 2.2 は、CALET のカロリメータ部分の概略図である。CALET では電荷測定器 (CHarge Detector:CHD) で電荷を測定し、粒子の識別をする。次にイメージング・カロリメータ (IMaging Calorimeter:IMC) で到来方向の情報を捉える。最後に、全吸収型カロリメータ (Total AbSorption Calorimeter:TASC) で入射粒子による電磁シャワーをすべて吸収してエネルギーを高精度で測定する [6]。

CALET は CHD、IMC、TASC によって電子、陽子、原子核、 γ 線などの様々な宇宙線のエネルギーおよび到来方向を高い精度で測定することができる。あわせて長期間の観測によって宇宙線のエネルギースペクトルを高精度で測定し、各宇宙線の謎の解明を目指している。特に宇宙線電子の観測では、TeV 領域の宇宙線電子の起源の解明や、ダークマターの対消滅の証拠となるスペクトルの探索が主な目的となる。




図 2.3 宇宙線電子スペクトルの測定結果 [3]。赤色のプロットが CALET での観測結果を示している。

図 2.3 では、2023 年に報告された CALET による宇宙線電子スペクトルの測定結果を示している。CALET での観測範囲は TeV 領域までに達し、7.5TeV までのスペクトルの測定がなされている [3]。一方で、高エネルギー領域の観測数が少なく、統計的な不確かさが大きい。

3 宇宙線電子

宇宙線電子 (Cosmic Ray Electron) は、宇宙線のうち、電子や陽電子のことを指す。地球で観測されている宇宙線電子のエネルギーは MeV から TeV スケールである。宇宙線電子の中でも、特に TeV 領域のエネルギーを持つ電子の起源は超新星残骸 (Super Nova Remnant: SNR) であると考えられている。宇宙線電子は質量が小さく、シンクロトン放射や逆コンプトン散乱によるエネルギー損失が大きいので、TeV 領域の宇宙線電子の伝播距離は $\lesssim 1\text{kpc}$ 、伝播年数は $\lesssim 10^5$ 年までに制限される [2]。したがって TeV 領域の宇宙線電子の起源は近傍の超新星残骸と考えることができる。

3.1 加速機構

3.1.1 衝撃波加速

宇宙線の加速機構についても依然はっきりとしたものは分かっていないが、現在の有力な加速機構は衝撃波加速 (Shock Acceleration) である [9]。超新星爆発によって生じた衝撃波の上流 (upstream) と下流 (downstream) の間を、荷電粒子が拡散的に往復することで統計的にエネルギーを獲得していく (図 3.1)。




図 3.1 衝撃波加速の模式図

衝撃波では、上流側 (SNR 側) の流速 v_{up} は下流側 (銀河側) の流速 v_{down} よりも大きく、荷電粒子が上流と下流を往復するたびに $\Delta v = v_{up} - v_{down}$ の速度差に比例してエネルギーを得る。1 往復するたびに Δv に比例して ξE だけエネルギーを得るとすると、 k 回の往復後のエネルギー E_k は

$$E_k = E_0(1 + \xi)^k \quad (3.1)$$

と書ける。ここで E_0 は初期エネルギーである。次に、1 回の往復で粒子が加速領域にとどまる確率を P とすると、 k 回の往復する確率は P^k となるので、 k 回往復した粒子の数 N_k は

$$N_k = N_0 P^k \quad (3.2)$$

となる。 N_0 は初期の粒子数である。式 3.1 を用いて k を消去すると、エネルギー E 以上の粒子数 $N(\geq E)$ は

$$N(\geq E) = N_0 \left(\frac{E}{E_0} \right)^{\frac{\log P}{\log(1+\xi)}} \quad (3.3)$$

単位エネルギーあたりの粒子数は

$$\frac{dN}{dE} \propto E^{-\left(1 - \frac{\log P}{\log(1+\xi)}\right)} = E^{-\gamma} \quad (3.4)$$

となる。ここで $\gamma = 1 - \frac{\log P}{\log(1+\xi)}$ である。

3.1.2 加速源でのカットオフエネルギー

衝撃波加速では超新星残骸の衝撃波によって宇宙線が加速するが、いくつかの理由で獲得するエネルギーには上限が存在する。まず、超新星残骸には寿命があり、粒子を加速する時間は有限である。ゆえに衝撃波面にとどまる時間は、往復する回数は有限であり、獲得するエネルギーにも制限がかかる。また、加速源近傍の磁場による散乱のスケールが超新星残骸の大きさを超えると、粒子は散乱を起こす前に超新星残骸から離脱してしまう。さらに、磁場による散乱によってシンクロトン放射が生じ、エネルギーが失われる。さらに宇宙線電子の場合はシンクロトン放射に加えて逆コンプトン散乱も生じ、より激しくエネルギーを失う。これらの要因によって、加速源における宇宙線のスペクトルには急激なカットオフが存在する。このカットオフエネルギー E_c によって、式 3.4 で考えた加速源での宇宙線スペクトル $Q(E) \propto \frac{dN}{dE}$ は

$$Q(E) = Q_0 E^{-\gamma} \exp\left(-\frac{E}{E_c}\right) \quad (3.5)$$

と表される [2]。 Q_0 は正規化定数である。このカットオフエネルギー E_c は超新星残骸の年齢、磁場の強さ、サイズに依存する。このカットオフエネルギーは、TeV 領域の宇宙線スペクトルに大きな影響を与えるため、本研究ではカットオフエネルギー E_c を機械学習によって予測することを目的とする。

3.2 伝播機構

宇宙線電子は電荷をもち、かつ軽い粒子のため銀河内磁場によって強く拡散される。また、同時にシンクロトン放射や逆コンプトン散乱によってエネルギーを失いながら伝播する。この宇宙線電子の拡散的な伝播は、拡散方程式 (Diffusion Equation) によって記述される。本研究で使用する伝播モデルでは、DRAGON コード [4] を使用する。DRAGON コードでは、宇宙線電子の伝播は以下の拡散方程式によって記述される。

$$\frac{\partial N_e}{\partial t} - \nabla \cdot (D \nabla N_e - \mathbf{v}_w N_e) - \frac{\partial}{\partial p} \left[p^2 D_{pp} \frac{\partial}{\partial p} \left(\frac{N_e}{p^2} \right) - \dot{p} N_e + \frac{p}{3} (\nabla \cdot \mathbf{v}_w) N_e \right] = Q_{SNR} + Q_{others} \quad (3.6)$$

N_e は宇宙線電子の数密度、 D は拡散係数、 $\mathbf{v}_w$ は銀河風速度、 p は運動量、 D_{pp} は運動量空間での拡散係数、 $\dot{p}$ はエネルギー損失率、 Q_{SNR} は超新星残骸からの宇宙線電子の供給項、 Q_{others} はその他の供給源からの宇宙線電子の供給項である。拡散係数 D はモデルによって異なる形をとる。超新星残骸からの供給項 Q_{SNR} は、式 3.5 の $Q(E)$ を用いて、

$$Q_{SNR}(E, \mathbf{r}, t) = Q(E) \delta^3(\mathbf{r} - \mathbf{r}_{SNR}) f_{SNR}(t) \quad (3.7)$$

$$= Q_0 E^{-\gamma} \exp\left(-\frac{E}{E_c}\right) \delta^3(\mathbf{r} - \mathbf{r}_{SNR}) f_{SNR}(t) \quad (3.8)$$

$f_{SNR}(t)$ は超新星残骸における電子の放出の時間発展を表す関数である。DRAGON コードでは式 3.6 をクラーク・ニコルソン法 (Crank-Nicolson Method) を用いて数値的に解くことで、太陽系やその近くの座標での宇宙線電子の分布を求める。これにより理論的な宇宙線電子のフラックスを得ることができる。これを実際の観測により得られたスペクトルにフィッティングさせる。さらに、そのスペクトルとフラックスの勾配を用いた異方性 [10] の計算と CALET の観測時間、方向を考慮したモンテカルロシミュレーションで宇宙線電子の観測サンプルを作成することができる。本研究では、この観測サンプルを統計的に十分な量作成し、機械学習させることで、観測データから超新星残骸の兆候の識別やカットオフエネルギー E_c の分類をすることを目的とする。

3.3 宇宙線電子のスペクトル

現在までの様々な宇宙線電子の観測によって、宇宙線電子のエネルギースペクトルが測定されてきた。観測が進捗するにつれて、観測されるエネルギー範囲も拡大しつつある。特に、地上観測実験の H.E.S.S.(2004～) や衛星実験である DAMPE(2015～) や CALET(2015～) では、その観測範囲は TeV 領域までに達し、1TeV 付近のスペクトルの折れ曲がりがあり有意に確認されている [3]。さらに、CALET では 7.5TeV まで観測が報告されている。一方で、高エネルギー領域の宇宙線電子は観測数が少なく、統計的な誤差が大きい。

3.3.1 近傍超新星残骸の寄与

現在までの CALET での観測では、図 2.3 のように 4~5TeV の間でスペクトルの硬化のようなものが見えており、近傍の超新星残骸からの寄与がある可能性が示唆されている。




図 3.2 近傍超新星残骸の寄与を考慮したフィッティング [3]

図 3.2 は、CALET の観測結果 (赤色のプロット) に近傍超新星残骸 (Vela SNR, Cygnus Loop, Monogem) の寄与を考慮した宇宙線電子スペクトルのフィッティングしたものである。このスペクトルフィッティング (黒色の実線) のフラックス Φ は以下の式 3.9、3.10、3.11 のように表される [11]。

$$\Phi = \Phi_e^- + \Phi_e^+ \quad (3.9)$$

$$\Phi_e^- = C_e E^{-(\gamma_e - \Delta\gamma_e)} \left(1 + \left(\frac{E}{E_b} \right)^{\frac{\Delta\gamma_e}{s}} \right)^s e^{-\frac{E}{E_{cutd}}} + \frac{C_s}{C_{norm}} \Phi_{s(e^-)} + \Phi_{pulsars} + \Phi_{nearSNR} \quad (3.10)$$

$$\Phi_e^+ = \frac{C_s}{C_{norm}} \Phi_{s(e^+)} + \Phi_{pulsars} \quad (3.11)$$

電子のフラックスは Φ_e^- 、陽電子のフラックスは Φ_e^+ (赤色の実線) である。 Φ_e^+ は AMS-02 の結果にフィッティングしてある。電子のフラックス Φ_e^- (式 3.10) は、遠い超新星残骸からの寄与 (第一項)、二次生成電子 (第二項)、パルサーからの寄与 (第三項)、近傍超新星残骸からの寄与 (第四項) で構成されている。陽電子のフラックス Φ_e^+ (式 3.11) は、二次生成陽電子 (第一項) とパルサーからの寄与 (第二項) で構成されている。近傍超新星残骸からの寄与 $\Phi_{nearSNR}$ (緑色の実線) は、近傍超新星残骸のカットオフエネルギーなどのパラメータによって形が決まる。フィッティングによってそれぞれの寄与の細かい形や位置などが決まる。

このフィッティングでは、TeV 領域に近傍超新星残骸の寄与がある可能性があることが示唆されている。一方で、高エネルギー領域の統計誤差の大きさと、10 TeV 以上の確立的な測定がまだ報告されておらず 1.7 TeV までしか bin 化したスペクトルが拡張できていないことから、このスペクトルに近傍超新星残骸の寄与があることを確定することは難しい。

4 機械学習

本研究ではモンテカルロシミュレーションによって得られた宇宙線電子の観測データをニューラルネットワークを用いて学習し、得られたヒットデータから超新星残骸の有無やカットオフエネルギーを予測することを目的とする。機械学習 (Machine Learning) は一般に、人工知能 (Artificial Intelligence: AI) にデータを学習させ、未知のデータに対して予測をする技術である。さらに機械学習は正解データを用いて学習を進める教師あり学習と、正解データなしで探索的に学習を進める教師なし学習に分けられる。本研究では教師あり学習を用いる。

4.1 機械学習の仕組み

機械学習 (以下では教師あり学習のみを指す) の大まかな構造は、入力→変換→出力である。はじめこの変換はランダムに設定されているが。入力データを出力データに変換した後、出力データと正解データの誤差 (Loss) を損失関数 (Loss Function) によって評価し、誤差を小さくするように変換を更新する。この変換の更新のことを“学習”(Training) と呼ぶ。




図 4.1 機械学習の流れ

この“学習”を繰り返すことで次第に出力が正解に近づいていき、学習用の入力データ (トレーニングデータ) 以外の未知の入力データに対しても正解に近い出力を返すことができる。

4.2 機械学習の構造

前節では機械学習における変換の構造については明らかにしていない。ここではその構造についてを例示的に説明する。まず、入力データは一般にテンソル (Tensor) で表現される。実際には 1 階のテンソルであるベクトルを用いることが多い。同様に、出力データもテンソルで表現される。それぞれのテンソルは入力層 (Input Layer)、出力層 (Output Layer) と呼ばれる。各層の要素 (成分) のことをノード (Node) と呼び、層間のノードの結合は重み (Weight) で関係づけられる。重みは結合の“強さ”と表現されることもある。一つの結合に対し、前の層のノードの値と重みの積が次の層のノードとなる。一つのノードに、前の層のノードが複数結合するときは、結合する前の層の各ノードと重みの積の総和が次の層のノードとなる。例えば、図 4.2 におけるノード M_1 の値は

$$M_1 = w_{11}I_1 + w_{12}I_2 + w_{13}I_3 + w_{14}I_4 \quad (4.1)$$

となる。ここで I_i は入力層のノード、 w_{ij} はノード I_i とノード M_j の結合の重みである。

このような層間のノードの結合の構造をニューラルネットワーク (Neural Network) と呼ぶ。図 4.2 のように前の層のすべてのノードが自身のノードと結合している層を全結合層 (Fully Connected Layer) という。

機械学習における変換はこのような重み付き和と活性化関数 (Activation Function) と呼ばれる非線形変換で構成される。普遍近似定理 (Universal Approximation Theorem) より、重み付き和とある条件を満たす非線形関数と十分な数のノードがあれば、任意の変換を近似的に生成することができることが知られている。重み付き和と活性化関数による非線形変換、および変換後のノードをまとめて層 (Layer) と呼ぶ。出力層やのちに述べる中間層はこれに該当する。入力層はこれに該当しないが、出力層や中間層と同じように層として扱うことが多い。




図 4.2 全結合層によるネットワーク構造の例

図 4.2 のように入力層と出力層のみでニューラルネットワークが構成される場合、出力層の i 番目のノード M_i は式 4.1 をより一般化して

$$M_i = \sum_j w_{ij} I_j \quad (4.2)$$

と書ける。ここで n 次元ベクトル $\mathbf{M}$ の第 i 成分を M_i 、 m 次元ベクトル $\mathbf{I}$ の第 j 成分を I_j とすると、式 4.2 は

$$(W)_{ij} = w_{ij} \quad (4.3)$$

と定義される $n \times m$ の重み行列 W を用いて、

$$\mathbf{M} = \mathbf{W}\mathbf{I} \quad (4.4)$$

と書ける。式 4.4 は重み付き和を行列で表現したものである。さらに、活性化関数となる非線形変換を T_{NL} とすると、最終的な出力層のノードのベクトル表示 $\mathbf{O}$ は

$$\mathbf{O} = T_{NL}(\mathbf{M}) = T_{NL}\mathbf{W}\mathbf{I} \quad (4.5)$$

と書ける。

4.3 深層学習

前節では機械学習における変換の構造について述べ、入力層と出力層のみの単層のニューラルネットワークの例を扱った。ここではさらに深層学習について述べる。深層学習は重み付き和と非線形変換で構成される層が複数存在するようなニューラルネットワークを用いた機械学習である。入力層と出力層の間に追加された層はすべて中間層 (Hidden Layer) に分類される。




図 4.3 深層学習におけるニューラルネットワークの構造

深層学習では層を複数重ねることで、入力から出力までの変換をより複雑にすることができ、複雑なデータの分類、予測が可能になる。理論上は、普遍近似定理より単層のみでも任意の変換を近似的に生成することができるが、必要なノードの数が膨大になってしまい、計算に時間がかかってしまう。一方で、層を重ねることで、より少ないノード数で複雑な変換を近似できる。

深層学習による中間層のノードをベクトル表示すると、図 4.3 のようにひとつ前の中間層のノードからの伝搬は 4.2 節と同様に行列表示を用いて

$$\mathbf{v}^{(k)} = T_{NL}^{(k)}(\mathbf{u}^{(k)}) = T_{NL}^{(k)} W^{(k)} \mathbf{v}^{(k-1)} \quad (4.6)$$

と書ける。ここで $\mathbf{v}^{(k)}$ は k 番目の中間層の非線形変換後のノードのベクトル表示、 $\mathbf{u}^{(k)}$ は k 番目の中間層の重み付き和後のノードのベクトル表示、 $W^{(k)}$ は k 番目の中間層の重み行列、 $T_{NL}^{(k)}$ は k 番目の中間層の非線形変換である。さらに、入力層を 0 番目の層、ベクトル表示を $\mathbf{I} = \mathbf{v}^{(0)}$ 、出力層を n 番目の層とすることで、出力層を含み、入力層を除いて n 個の層で構成されたニューラルネットワークの出力層のノードのベクトル表示 $\mathbf{O}$ は

$$\mathbf{O} = \mathbf{v}^{(n)} = T_{NL}^{(n)} W^{(n)} T_{NL}^{(n-1)} W^{(n-1)} \dots T_{NL}^{(k)} W^{(k)} \dots T_{NL}^{(1)} W^{(1)} \mathbf{v}^{(0)} \quad (4.7)$$

と書ける。

4.4 損失関数と最適化

損失関数 (Loss Function) による重みの更新は、機械学習において最も核心的な部分である。一般に損失関数は出力データと正解データの誤差を表す関数であり、この損失関数を小さくすることで“学習”を進め、予測の精度を上げる。したがって“学習を”を進めることは損失関数を最小にするような最適化問題を解くことに他ならない。この最適化問題は一般に勾配降下法 (Gradient Descent Method) を用いて解かれる。

4.4.1 勾配降下法

損失関数は出力データ $\mathbf{O}$ と正解データ $\hat{\mathbf{O}}$ を用いて $L(\mathbf{O}, \hat{\mathbf{O}})$ と表される。出力データ $\mathbf{O}$ は重み $W^{(k)}$ に依存するので、損失関数 L も重み $W^{(k)}$ に依存する。したがって、損失関数 L の重み $W^{(k)}$ 方向の勾配 $\frac{\partial L}{\partial W^{(k)}}$ を計算でき、勾配の逆方向、つまり L が小さくなる方向に重みを平行移動させればよい。つまり、現在の重みを $W_{old}^{(k)}$ 、学習率 (Learning Rate) を η とすると、新たに更新された重み $W_{new}^{(k)}$ は

$$W_{new}^{(k)} = W_{old}^{(k)} - \eta \left. \frac{\partial L}{\partial W^{(k)}} \right|_{W^{(k)}=W_{old}^{(k)}} \quad (4.8)$$

と書ける。これを逐次的に繰り返すことで損失関数 L を小さくし、“学習”を進める。学習率 (Learning Rate) η は一回の更新でどれだけ重みを変化させるかを決定するパラメータである。学習率 η が大きすぎると、損失関数が最小にならずに発散してしまう。逆に、学習率 η が小さすぎると極小に陥ってしまい、真の最小値に到達できないことがある。

4.4.2 誤差逆伝播法

重みを更新するために損失関数の重み方向の勾配を計算する必要がある。この勾配の計算には誤差逆伝播法 (Back Propagation Method) が用いられる。誤差逆伝播法は入力→出力とは逆方向に勾配を計算し、重みを更新する方法である。まず、出力層のにつながる重み $W^{(n)}$ 方向の損失関数 $L(\mathbf{O}, \hat{\mathbf{O}})$ の勾配は $\mathbf{O} = T_{NL}W^{(n)}\mathbf{v}^{(n-1)}$ より、

$$\frac{\partial L}{\partial W^{(n)}} = \frac{\partial L}{\partial \mathbf{O}} \cdot \frac{\partial \mathbf{O}}{\partial W^{(n)}} \quad (4.9)$$

と書ける。さらにひとつ前の重み $W^{(n-1)}$ 方向の損失関数 $L(\mathbf{O}, \hat{\mathbf{O}})$ の勾配は

$$\frac{\partial L}{\partial W^{(n-1)}} = \frac{\partial L}{\partial W^{(n)}} \frac{\partial W^{(n)}}{\partial \mathbf{v}^{(n-1)}} \cdot \frac{\partial \mathbf{v}^{(n-1)}}{\partial W^{(n-1)}} \quad (4.10)$$

つまり、微分の連鎖率を使えば、 k 番目の重み $W^{(k)}$ 方向の損失関数 $L(\mathbf{O}, \hat{\mathbf{O}})$ の勾配は

$$\frac{\partial L}{\partial W^{(k)}} = \frac{\partial L}{\partial W^{(k+1)}} \frac{\partial W^{(k+1)}}{\partial \mathbf{v}^{(k)}} \cdot \frac{\partial \mathbf{v}^{(k)}}{\partial W^{(k)}} \quad (4.11)$$

任意の k での勾配は、その次 $k+1$ での勾配を用いて計算できる。したがって、出力層から逆方向に順次勾配を計算していくことで、すべての重み $W^{(k)}$ 方向の損失関数 $L(\mathbf{O}, \hat{\mathbf{O}})$ の勾配を効率的に計算できる。

4.5 機械学習モデル構造

本研究で用いる機械学習モデル構造について述べる。基本の構造は各層のノードが全結合層で結ばれたニューラルネットワークである。学習の目的や入力データの構造に応じて、特殊なネットワーク構造を用いる。

4.5.1 残差接続ネットワーク

一般に、深層学習のように層を深くするほど、より複雑な変換の近似が可能になる。しかし、同時に学習が層が深くなるほど誤差逆伝播によって浅い層に伝わる勾配が小さくなり、浅い層の学習が進まなくなる勾配消失 (Gradient Loss) の問題が発生する。この問題を解決するために、残差接続ネットワーク (Residual

Network:ResNet) が導入された。残差接続ネットワークでは、出力そのものではなく、出力と入力との差分 (残差:Residual) を学習する。具体的には、とある層の入力 $x = v^{(l)}$ に対し、いくつか層を通過した後の出力 $y = v^{(m)}$ を

$$y = x + F(x) \quad (4.12)$$

と表す。ここで F は中間層における通常の変換 $T^{(m)}W^{(m)} \dots T^{(l+1)}W^{(l+1)}$ である。




図 4.4 残差接続ネットワークの構造

残差接続ネットワークでは残差 $y - x = F(x)$ の勾配を求めることで学習を進める。誤差逆伝播法によって損失関数 L の勾配を計算すると、

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \left(1 + \frac{\partial F}{\partial x} \right) \quad (4.13)$$

となる。したがって、 $\frac{\partial F}{\partial x}$ が小さくなくても勾配が完全に消失することがないので、浅い層の学習が進まなくなる問題を軽減できる。残差接続ネットワークは図 4.4 のように、入力 x を変換 F に入れる前に分岐 (スキップ) させて出力と合流する構造となる。故に既存の全結合層に容易に組み込むことができる。

4.5.2 畳み込みニューラルネットワーク




図 4.5 畳み込みニューラルネットワークにおける畳み込み演算

入力データが画像データのように、隣接するデータ同士に強い相関がある場合、畳み込みニューラルネットワーク (Convolutional Neural Network:CNN) が用いられる。畳み込みニューラルネットワークでは、全結合

層の代わりに畳み込み層 (Convolutional Layer) を用いる。畳み込み層では、フィルター (Filter) と呼ばれる重みテンソルを入力データに対して演算させる。例えば、図 4.5 のように 2 次元の画像データの場合は $n \times n$ のフィルター (重み行列) を画像の各ピクセルに対して、その周りの $n \times n$ のピクセル領域に適用し、フロベニウス内積を計算する。これを全ピクセルに対して行うことで、特徴マップ (Feature Map) と呼ばれる新たな画像データを生成する。

さらに、畳み込みの後にはプーリング層 (Pooling Layer) を挟むことが多い。プーリング層では、特徴マップの中で最大値を取る最大プーリング (Max Pooling) や平均値を取る平均プーリング (Average Pooling) などの演算を行い、特徴マップのサイズを縮小する。プーリング層による変換は非線形変換であり、全結合層における活性化関数と同様に変換の多様化の役割がある。また、特徴マップのサイズを縮小することで計算量を削減し、過学習 (Overfitting) を防止する効果もある。

5 機械学習に使用するデータと観測サンプル

5.1 観測サンプルの作成

本研究では式 3.6 に基づいた DRAGON コード [4] による計算で得られたフラックスのスペクトルフィッティングと異方性の計算 [10]、観測条件から生成された宇宙線電子のモンテカルロシミュレーションの観測サンプルを学習データに用いる。CALET による 7 年、8 年、14 年の観測を想定して Motz [12]、玉置 [7] によって作成された観測サンプルを使用する。今回使用したシミュレーションにおける伝播モデル [13] では、拡散係数 D は以下のように設定されている。

$$D(r, z, R) = D_0 \max \left\{ e^{\frac{r-r_n}{r_s}}, 1 \right\} \max \left\{ e^{\frac{z-z_n}{z_s}}, 1 \right\} \left(\frac{R}{R_0} \right)^{\delta_l} \left(1 + \left(\frac{R}{R_{bl}} \right)^{\frac{\delta_l - \delta}{s_l}} \right)^{s_l} \left(1 + \left(\frac{R}{R_{bh}} \right)^{\frac{\delta - \delta_h}{s_h}} \right)^{-s_h} \quad (5.1)$$

今回使用した伝播モデル、式 5.1 における各パラメータの値は表 5.1 に示されている。

表 5.1 使用したモデルの各パラメータとその値 [7]

パラメーター	D_0 [$10^{28} \text{ cm}^2/\text{s}$]	R_0 [GV]	L [kpc]	v_a [km/s]	γ_l	R_{bi} [GV]	s_{bi}	γ_i	R_{cut} [TV]	w_{sa} [kpc]
値	3.066	4	6	14.74	2.030	13.45	0.2285	2.344	30.12	0.6478

r_n [kpc]	r_s [kpc]	z_n [kpc]	z_s [kpc]	δ_l	R_{bl} [GV]	s_l	δ	R_{bh} [GV]	s_h	δ_h
2	10.7	0.15	4.50	0.2112	8.4373	0.0529	0.5141	913.5	0.3262	0.0018

また通常、宇宙線電子の伝搬の計算には想定する超新星残骸の性質を示す以下のパラメータを設定して DRAGON コードを実行する。

- 超新星残骸のカットオフエネルギー E_c
- 放出時間 T
- 想定する SNR(位置、年齢など)

放出時間は超新星爆発から T までの一定で連続な電子の放出時間であり、式 3.7 における $f_{SNR}(t)$ を決定する。玉置 [7] によって作成されたサンプルでは、カットオフエネルギーは 10 TeV と 100 TeV の 2 種類、放出時間は 0 年と 10000 年の 2 種類で設定されている。想定する超新星残骸は Vela SNR のみ、Vela SNR、Cygnus Loop、Monogem の 3 つが含まれたサンプルの 2 種類である。Motz [12] によって作成されたサンプルでは、カットオフエネルギーは 10 TeV、20 TeV、50 TeV、100 TeV の 4 種類、放出時間は 0 年、2500 年、5000 年、7500 年、10000 年の 5 種類で設定されている。想定する超新星残骸は Vela SNR のみ、Vela SNR、Cygnus Loop、Monogem の 3 つが含まれたサンプル、SNR なしのサンプルの 3 種類である。今回シミュレーションの対象となった 3 つの超新星残骸、Vela SNR、Cygnus Loop、Monogem は宇宙線電子の起源の候補となる近傍超新星残骸の中でも特に寄与が強く、TeV 領域に痕跡を残すと考えられている 3 つである。これら 3 つの超新星残骸の位置や年齢は表 5.2 に示されている。

表 5.2 近傍超新星残骸の年齢、太陽系からの距離、銀河座標での緯度と経度

名前	年齢 (year)	太陽系からの距離 (pc)	経度 (Longitude)	緯度 (Latitude)
Vela	1.1×10^4	300	263.9	-3.3
Cygnus Loop	2.0×10^4	440	74.0	-8.5
Monogem	8.6×10^4	300	201.1	8.3

Motz[12]によって作成されたサンプルの集合を“サンプル群 A”、玉置 [7]によって作成されたサンプルの集合を“サンプル群 B”と呼ぶことにする。サンプル群 A では、各パラメータの組み合わせごとに 1000 個のサンプルが作成されている。一方、サンプル群 B では、各パラメータの組み合わせごとに 5000 個のサンプルが作成されている。それぞれのサンプル群における想定されているパラメータの組み合わせは表 5.3、表 5.4 に示されている。

表 5.3 サンプル群 A における各パラメータの設定

パラメータ名	SNR	観測時間
設定	SNR なし, Vela のみ, Vela, Cygnus Loop, Monogem	8 年, 14 年
パラメータ名	放出時間	E_c
設定	0 年, 2500 年, 5000 年, 7500 年, 10,000 年	10TeV, 20TeV, 50TeV, 100TeV

表 5.4 サンプル群 B における各パラメータの設定

パラメータ名	SNR	観測時間
設定	Vela のみ, Vela, Cygnus Loop, Monogem	7 年, 14 年
パラメータ名	放出時間	E_c
設定	0 年, 10,000 年	10TeV, 100TeV

5.2 機械学習用データセットの作成

作成された観測サンプル群 A、B から機械学習に使用できるようにデータを整形する。まず、機械学習データセットには直接的に特徴の学習に使用する“学習データ”と、未知データに対しての適応力を評価するための“テストデータ”が必要である。本研究では、各パラメータの組み合わせごとに、半分のサンプルを学習データ、もう半分をテストデータに使用する。サンプル群 A に対しては学習・テストデータそれぞれ 500 サンプルずつ、サンプル群 B に対しては学習・テストデータそれぞれ 2500 サンプルずつ割り当てる。さらに、学習およびテストデータは入力データと正解ラベルの列構造 (図 5.1) になっており、各正解ラベルにつき割り当てられたサンプル数だけデータがあるので、割り当てられたサンプル数 $\times$ 正解ラベルのクラス数だけの長さをもつ構造になっている。入力データには観測サンプルのヒットデータを用いるものとし、正解ラベルには 5.1 節で述べた超新星残骸のパラメータのうち、予測させたいものを選択する。その他のパラメータは固定する。サンプル群 B を用いてカットオフエネルギー E_c を予測するタスクの場合、正解ラベルは 10 TeV と 100 TeV の 2 クラスになるので、学習データは 2500 サンプル $\times$ 2 クラス = 5000 個、テストデータも同様に 5000 個のデータをもつことになる。

割り当てられたサンプル数N		入力データ	正解ラベル	割り当てられたサンプル数N×ラベルのクラス数
	{	Hitdata 1-1	Label 1	
		Hitdata 1-2	Label 1	
		⋮	⋮	
		Hitdata 1-N	Label 1	
		Hitdata 2-1	Label 2	
		⋮	⋮	
		Hitdata 2-N	Label 2	
		⋮	⋮	

図 5.1 学習およびテストデータの構造

6 機械学習モデルの作成

本研究で行った機械学習タスクは以下の 2 つである。

- タスク 1: 近傍超新星残骸の兆候の識別
- タスク 2: 超新星残骸のカットオフエネルギー E_c の分類

タスク 1 はサンプル群 A を用いて、「SNR なし」と「Vela のみ」をラベルとして予測させ、機械学習によって近傍超新星残骸の兆候の識別が可能かどうかを評価するタスクである。一方、タスク 2 はサンプル群 B を用いて、10 TeV または 100 TeV のカットオフエネルギー E_c をラベルとして予測させ、機械学習によって超新星残骸のカットオフエネルギーの分類が可能かどうかを評価するタスクである。それぞれのタスクに対して機械学習モデルを作成した。

機械学習モデルの作成には Python の深層学習ライブラリである TensorFlow を用いた。機械学習モデルの作成にはニューラルネットワーク構造の設計や、学習に必要なパラメータの設定が必要である。特にモデルの性能を大きく左右するパラメータ (以下、ML パラメータと呼ぶ) に、活性化関数、損失関数、学習率、バッチサイズ (Batch Size)、待機回数 (Patience) などがある。待機回数は、学習の途中でテストデータに対する損失関数が改善しなくなった場合に学習を早期に終了させ過学習を防ぐためのパラメータである。モデルの性能の向上のためにはこれら ML パラメータの適切な設定や最適化が必要である。以下ではそれぞれのタスクと作成した機械学習モデルの詳細について述べる。

6.1 タスク 1: 近傍超新星残骸の兆候の識別

タスク 1 は、サンプル群 A を用いて「SNR なし」と「Vela のみ」の 2 クラスに分解し、近傍超新星残骸のうち最も寄与が強いとされている Vela SNR の寄与を識別するタスクである。使用する Vela のあり・なしおよびカットオフエネルギー以外の超新星残骸のパラメータ (以下、SNR パラメータとする) は固定し、想定する超新星残骸は Vela のみ、放出時間は 10,000 年、観測時間は 8 年に設定した。カットオフエネルギーに関しては、その違いによる識別率の影響を調べるために E_c は 10 TeV、20 TeV、50 TeV、100 TeV の 4 種類を想定する。タスク 1 のような 2 クラスに分類するタスクは、二値分類問題 (Binary Classification Problem) に該当する。二値分類問題では、出力の値を 0 から 1 の値に正規化し、0.5 以上をクラス 1、0.5 未満をクラス 0 に分類する。ただし、本タスクでは後に「Vela, Cygnus Loop, Monogem」とあわせて 3 つの分類をする可能性を考慮して、出力層に softmax 関数 (Softmax Function) を用いて、出力を 2 値化した。「SNR なし」のラベルを 0、「Vela のみ」のラベルを 1 とし、出力層に softmax 関数を用いて、出力を 0 から 1 の値に正規化した。入力データには、到来する電子のエネルギーの Vela 方向への偏りを期待して、エネルギーの到来方向マップ用いる。具体的には、まずサンプルのヒットデータ (エネルギー, 到来方向) のうち、到来方向を HEALPix の $n_{\text{side}}=64$ で区切った 4,9152 個のピクセルに分け、各ピクセルに到来した電子のエネルギーの最高値を入力用データとした。このうち 500 GeV 以上のエネルギーをプロットしたものが図 6.1 である。本タスクでは m GeV 以上のエネルギーデータのみをプロットするものとし、このエネルギー閾値 m はハイパーパラメータとして扱う。




図 6.1 エネルギーの到来方向マップの例 (Vela SNR ありの場合)。エネルギーは対数スケールで表示しており、単位は GeV である。全天を Mollweide 投影で表示している。

さらに、このマップを長方形に変換し、解像度を 128×256 まで縮めたものを、行列表示による 2 次元画像データとして入力データに用いる (図 6.2)。




図 6.2 入力画像データの例 (Vela SNR ありの場合)

本タスクにおけるニューラルネットワークの構造は、まず、 128×256 のノードを持つ入力層から始まり、これを 100×100 のフィルター 16 個を用いて畳み込む。これをさらに `sparse_plus` による活性化を行い、Average Pooling(AP) で縮小する。さらに 5×5 のフィルターによる畳み込み、活性化の層を n 回繰り返す。

このうち、4 回に 1 回の層ではフィルターの数を 1/2 に減らし、活性化の後に Max Pooling(MP) を挟む。次に過学習防止用の Drop out を通した後に、Global Average Pooling(GAP) で特徴マップを 1 次元に変換する。最後に全結合層を通して softmax による出力層で終わる構造を作成した (図 6.3)。本タスクでは n をパラメータとして扱う。中間の n 個の層には残差接続ネットワークを組み込んだ。損失関数にはクラス分類問題でよく使われるカテゴリカルクロスエントロピー (Categorical Cross-Entropy) を採用し、学習率は 0.0001、バッチサイズは 100、待機回数は 100 に設定した。中間層の活性化関数を sparse_plus に設定した理由は、パラメータ走査の結果、ReLU 関数や tanh 関数などの他の活性化関数よりも損失の収束が早かったためである。学習率は小さいほうが正解率が高くなったが、小さすぎると学習が進まないため 0.0001 に設定した。タスク 1 で設定した SNR パラメータと ML パラメータの値は表 6.1、表 6.2 に示されている。




図 6.3 タスク 1 で作成した学習モデル

表 6.1 タスク 1 で設定した SNR パラメータ

パラメータ名	観測時間	放出時間	E_c
設定	8 年	10,000 年	10 TeV, 20 TeV, 50 TeV, 100 TeV

表 6.2 タスク 1 で設定した ML パラメータ

パラメータ名	活性化関数	損失関数	学習率	バッチサイズ	待機回数
設定	sparse_plus	categorical cross-entropy	0.0001	100	100

6.2 タスク 2: 超新星残骸のカットオフエネルギー E_c の分類

タスク 2 は、サンプル群 B を用いて、超新星残骸のカットオフエネルギー E_c を 10 TeV または 100 TeV の 2 クラスに分類するタスクである。カットオフエネルギー以外の SNR パラメータは固定し、想定する超新星残骸は Vela のみ、放出時間は 10,000 年、遅延時間は 10,000 年、観測時間は 14 年に設定した。




図 6.4 $E_c=10$ TeV のときのスペクトルフィッティングの結果




図 6.5 $E_c=100$ TeV のときのスペクトルフィッティングの結果

図 6.4、図 6.5 はカットオフエネルギーが 10 TeV、100 TeV の場合のスペクトルフィッティングの結果である。これらに対して異方性と CALET による 14 年の観測を考慮し作成した観測サンプルを学習させる。

タスク 2 も同様に二値分類問題に該当する。本研究では、10 TeV のラベルを 0、100 TeV のラベルを 1 とし、出力層にシグモイド関数 (Sigmoid Function) を用いて、出力を 0 から 1 の値に正規化した。使用する入

カデータは、観測サンプルのヒットデータのうち、最もエネルギーが大きい l 個のエネルギーデータのリストである。 l の値はハイパーパラメータとして設定した。ニューラルネットワークの構造は、全結合層および残差接続ネットワークを組み合わせたものである。 l 個のノードを持つ入力層から始まり、 n 個の中間層を経て、1 個のノードを持つ層をの値をさらに sigmoid 関数で正規化した出力層で終わる構造を作成した (図 6.6)。中間層は $\min\{l, 1024\}$ 個のノードを持つ層から始まり、層が n 個になるように線形にノード数を減らしていく。本タスクでは n をパラメータとして扱う。各層は全結合しており、出力以外の活性化関数はタスク 1 と同様に、`sparse_plus` を用いた。損失関数には二値分類問題でよく使われる二値交差エントロピー (Binary Cross-Entropy) を採用し、学習率は 0.0001、バッチサイズは 100、待機回数は 100 に設定した。タスク 2 で設定した SNR パラメータと ML パラメータの値は表 6.3、表 6.4 に示されている。




図 6.6 タスク 2 で作成した学習モデル

表 6.3 タスク 2 で設定した SNR パラメータ

パラメータ名	SNR	観測時間	放出時間
設定	Vela のみ	14 年	10,000 年

表 6.4 タスク 2 で設定した ML パラメータ

パラメータ名	活性化関数	損失関数	学習率	バッチサイズ	待機回数
設定	sparse_plus	binary cross-entropy	0.0001	100	100

7 学習の結果と評価

前章で作成した機械学習モデルを用いてそれぞれのタスクについて学習を行い、その結果と評価について述べる。なお、学習の評価には検証損失 (Validation Loss)、正解率 (Accuracy)、偽陽性率 (False Positive Rate: FPR)、偽陰性率 (False Negative Rate: FNR) を用いた。検証損失はテストデータに対する出力とラベルの誤差 (損失) である。正解率はデータをモデルに入力したとき、出力が正解ラベルと一致した割合を表す指標である。本研究では、テストデータのみに対して正解率を計算した。偽陽性率は、実際にシグナルがないデータに対してシグナルありと誤認識した割合を表す指標であり、偽陰性率は、実際にシグナルがあるデータに対してシグナルなしと誤認識した割合を表す指標である。検証損失は学習の途中で定めても定義できるので、学習のどの段階でモデルの性能が良いかを評価するのに用いられる。一方、正解率や偽陽性率、偽陰性率は学習が完了した後に定義される指標であり、最終的なモデルの性能を評価するのに用いる。学習の途中で最も小さかった検証損失をモデルの性能と位置付ける。

7.1 タスク 1: 近傍超新星残骸の兆候の識別

タスク 1 では、サンプル群 A を用いて、「SNR なし」と「Vela のみ」をラベルとして予測させ、機械学習によって近傍超新星残骸の兆候の識別が可能かどうかを評価するタスクである。本タスクでは図 6.3 における層の数 n とエネルギー閾値 m をハイパーパラメータとして学習を走査 (Scan) し、検証損失が最小となる組み合わせを探索する。層の数 n は 0 から 10 までの 2 刻みで、エネルギー閾値 m は 100 GeV から 1000 GeV まで 100 GeV 刻みで走査した。また、カットオフエネルギー E_c を変えながら走査し、正解率や検証損失がの違いや、検証効率の極小の変化などを調べた。 $E_c=10$ TeV の走査の結果は図 7.1 に、 $E_c=20$ TeV の走査の結果は図 7.2 に、 $E_c=50$ TeV の走査の結果は図 7.3 に、 $E_c=100$ TeV の走査の結果は図 7.4 に示されている。







図 7.1 タスク 1 の学習結果 ($E_c=10$ TeV)

図 7.2 タスク 1 の学習結果 ($E_c=20$ TeV)図 7.3 タスク 1 の学習結果 ($E_c=50$ TeV)

図 7.4 タスク 1 の学習結果 ($E_c=100$ TeV)

四つの図について、左側のプロットに最小の検証損失の走査結果、右側のプロットに最小の検証損失を達成したときのエポック数を示している。それぞれ色でプロットしてある。エポック数とは、学習の進行度を示す指標であり、学習データ全体を一通り学習させた回数を表す。各プロットの横軸は層の数 n 、縦軸はエネルギー閾値 m である。

$E_c=10$ TeV のとき、検証損失が最小となったのは、層の数 $n = 0$ 、エネルギー閾値 $m = 300$ GeV の組み合わせであり、検証損失は 0.310 であった。このときのエポック数は 138 であった。このエポック数で、再度 $(n, m) = (0, 300)$ の学習を行い、テストデータに対する正解率を求めたところ、85.5% であった。さらに、この組み合わせにおける偽陽性率を、偽陰性率を求めたところ、それぞれ 8.8%、20.0% であった。ただし、この識別タスクにおける偽陽性率とは、実際には SNR なしであるサンプルを Vela のシグナルありと誤識別した割合を指し、偽陰性率とは、実際には Vela ありであるサンプルを SNR なしと誤識別した割合を指す。同様に、 $E_c=20$ TeV では $(n, m) = (0, 400)$ で検証損失が最小値 0.355、正解率が 83.5%、偽陽性率が 16.5%、偽陰性率が 21.6% であった。 $E_c=50$ TeV では $(n, m) = (0, 400)$ で検証損失が最小値 0.388、正解率が 82.3%、偽陽性率が 14.8%、偽陰性率が 26.1% であった。 $E_c=100$ TeV では $(n, m) = (0, 400)$ で検証損失が最小値 0.444、正解率が 81.2%、偽陽性率が 16.0%、偽陰性率が 28.8% であった。タスク 1 におけるそれぞれのカットオフにおける、最も学習の結果が良かった組み合わせおよびその性能を表 7.1 に示す。それぞれ、5 回の学習を行い、その平均値をとった。

表 7.1 タスク 1 における各カットオフエネルギーでの最良結果

E_c (TeV)	(n, m)	最小検証損失	正解率 (%)	偽陽性率 (%)	偽陰性率 (%)
10	(0, 300)	0.402	81.0	19.6	18.4
20	(0, 400)	0.355	84.0	15.3	16.7
50	(0, 400)	0.310	85.7	12.2	16.4
100	(0, 400)	0.338	84.4	15.1	16.1

図 7.1～図 7.4 から、エネルギー閾値 m は大きすぎても小さすぎても予測が難しくなる傾向があることが分かる。これは、閾値が小さい場合は Vela SNR の寄与が小さく背景信号が大きい低エネルギー領域のデータが乗ってしまい、Vela の寄与が識別しづらくなっていると考えられる。一方で、閾値が大きい場合は、高エネルギー領域のデータ数が少ないことから、統計的な揺らぎが大きく、特徴の識別が難しくなると考えられる。つ

まり、統計量が十分にあり、かつ Vela SNR の寄与が大きいエネルギー領域を選択することで、識別の可能性が高くなると分かる。

同じく 4 つの図から、カットオフエネルギーが大きくなるほど検証効率の最小の部分が m の高エネルギー側にシフトしていることが分かる。これは先ほどの議論とあわせると、カットオフエネルギーが大きくなるにつれて、その特徴を残すエネルギー領域が大きくなっていることを示している。一方で、正解率や偽陽性率、偽陰性率の関しては、カットオフエネルギー $E_c=50$ TeV のときが最も良く、それより大きい 100 TeV や小さい 10 TeV、20 TeV では悪化する傾向がある。これも先ほどの議論と照らし合わせると、カットオフエネルギーが大きいと Vela SNR の寄与も高エネルギー側に位置するため、高エネルギー領域の統計量の少なさから識別能力が下がるのではないかと考えた。同様にカットオフエネルギーが小さいと Vela SNR の寄与も低エネルギー側に位置するため、背景信号に埋もれてしまい識別が難しくなるのではないかと考えた。

続いて、検証損失は層の数 n が小さいほど小さくなる傾向にあり、特に $n=0$ では 100×100 のフィルターによる畳み込みと活性化、AP による $1/16$ 縮小のみで構成されている。つまり、エネルギー到来方向マップの大規模な構造のみをとらえることで、Vela SNR の寄与が識別しやすくなると分かる。一方で、層が重なるほど検証損失が大きくなる傾向がある。これは、層が深くなるほど学習データの細部を過剰に学習して、未知データに対する適応力が下がる、いわゆる過学習の影響であると考えられる。

本タスクでは正解率が 81~85% ほどを達成した。また、偽陽性率および偽陰性率は 12~20% ほどになった。これより、畳み込みネットワークを用いた機械学習によって、近傍超新星残骸の兆候の識別がある程度高い精度で可能であるが、5~8 回に 1 回超新星残骸がないサンプルから Vela の信号を読み取る程度の精度であると評価できる。また、カットオフエネルギー E_c によって識別の力に差があることが確認できた。

7.2 タスク 2: 超新星残骸のカットオフエネルギー E_c の分類

タスク 2 では、サンプル群 B を用いて、超新星残骸のカットオフエネルギー E_c を 10 TeV または 100 TeV の 2 クラスに分類するタスクである。本タスクではエネルギーの入力データの長さ l と中間層の数 n をハイパーパラメータとして学習を走査 (Scan) し、検証損失となる組み合わせを探索する。走査の範囲は、入力データの長さ l が 1000 から 10000 まで 1000 刻みで、層の数 n が 0 から 11 まで 1 刻みである。走査は 5 回行い、各組合せの中で平均をとっている。走査の結果は図 7.5 に示されている。




図 7.5 タスク 2 の学習結果

左側のプロットには各組合せでの最小検証損失の走査結果、右側のプロットには最小の検証損失を達成したときの平均エポック数を示している。各プロットの横軸は層の数 n 、縦軸は入力データの長さ l である。

本タスクに対して検証損失が最小となったのは、入力データの長さ $l = 3000$ 、中間層の数 $n = 1$ の組み合わせであり、検証損失は 0.206 であった。このときの平均エポック数は 92 であった。このエポック数で、再度 $(n, l) = (1, 3000)$ の学習を行い、テストデータに対する正解率を求めたところ、91.2% であった。さらに、この組み合わせにおける偽陽性率を、偽陰性率を求めたところ、それぞれ 8.1%、9.5% であった。ただし、この分類タスクにおける偽陽性率とは、実際には 10 TeV であるサンプルを 100 TeV と誤分類した割合を指し、偽陰性率とは、実際には 100 TeV であるサンプルを 10 TeV と誤分類した割合を指す。最も学習の結果が良かった $(n, l) = (1, 3000)$ の組み合わせでの性能を表 7.2 に示す。それぞれ、5 回の学習を行い、その平均値をとった。

表 7.2 タスク 2 における最も良い結果

(n, l)	最小検証損失	正解率 (%)	偽陽性率 (%)	偽陰性率 (%)
(1, 3000)	0.206	91.2	8.1	9.5

最も高い 3000 個のエネルギーデータがどのエネルギー範囲に分布しているかを調べるために、10 TeV および 100 TeV のサンプルに対して、 l 番目に大きいエネルギーデータの 5000 サンプルの平均を求めた (図 7.3)。 $l=3000$ のときは、それぞれ 548 GeV、543 GeV であった。したがって、この 10 TeV と 100 TeV の分類タスクにおいて、その特徴を残すエネルギー領域は約 500 GeV 以上であることが分かった。また、入力データ数 l が小さい範囲ではより高エネルギー領域を参照しているが、高エネルギー領域の統計の少なさから、カットオフエネルギーの情報をつかむのが難しいと考えられる。入力データ数 l が大きい場合、低エネルギーから高エネルギー領域を幅広く参照しているが、Vela の寄与が小さく背景シグナルの大きい低エネルギー領域の情報が大きく乗っているため、こちらも分類が難しくなる傾向があると考えられる。

表 7.3 各入力データ数 l における最小エネルギーデータの平均値

入力データ数 l	平均最小エネルギー (10 TeV の場合)	平均最小エネルギー (100 TeV の場合)
1000	824 GeV	809 GeV
2000	639 GeV	631 GeV
3000	548 GeV	543 GeV
4000	491 GeV	487 GeV
5000	449 GeV	446 GeV
6000	417 GeV	415 GeV
7000	392 GeV	390 GeV
8000	371 GeV	369 GeV
9000	353 GeV	352 GeV
10000	337 GeV	337 GeV

層の数 n が 1 のときが比較的良好な結果を出すということが図 7.5 から読み取れるが、 $n=1$ は非線形変換が 1 回の比較的単純なモデルであり、10 TeV と 100 TeV のヒットデータの違いが比較的識別しやすいことが分かる。反対に、層を重ねてしまうとデータの細部を過剰に学習してしまうと考えられる。 $n=0$ の場合だけは挙動が他と異なり、入力データ数 l を増やすほど検証損失が小さくなることが読み取れる。 $n=0$ は、非線形変換を含まない単純なロジスティック回帰モデルであることを意味し、このロジスティック回帰のほうが、低エネルギー領域でのカットオフエネルギー特徴の認識能力が高いのではないかと考えられる。

本タスクでは最大で 91.2% の正解率を達成した。また、分類ミスをする割合 (偽陽性率および偽陰性率) も 8.1%、9.5% であった。これにより機械学習によって超新星残骸のカットオフエネルギー E_c の分類が高い精度で可能であり、約 11~12 回に 1 回の割合で分類ミスをする程度の精度であると評価できる。

8 まとめと今後の展望

8.1 まとめ

TeV 領域の宇宙線電子の起源となる天体は、電子の激しいエネルギー損失から“近傍”の超新星残骸であると考えられているが、高エネルギー領域における観測は観測数が少なく、統計誤差が大きいため bin によるスペクトルフィッティングでは、確定的な寄与は未だ発見されていない。したがって、スペクトルフィッティングに頼らず高エネルギー領域のデータを直接解析する新たな解析手法の確立が求められている。現在、機械学習は近年様々な分野で注目されており、物理学実験においても応用が進んでいる。宇宙線電子の起源に関するこの問題に対して、機械学習を導入してアプローチするのがこの研究の目的である。

本研究では、理論的なスペクトルと異方性から CALET での観測を考慮したモンテカルロシミュレーションで作成された観測サンプルと機械学習モデルを用いて機械学習を実行し、CALET のヒットデータに現れる近傍超新星残骸の兆候の識別および分類が可能かどうかの評価を行った。学習の結果、「SNR なし」と「Vela のみ」をラベルとして予測させるタスクにおいて、最大で 81~85% の正解率を達成し、近傍超新星残骸の兆候の識別が可能であることが確認できた。また、識別において、最も寄与の特徴を残すエネルギー領域は 300~500 GeV 以上であり、その識別能力はカットオフエネルギー E_c に依存することが分かった。これにより超新星残骸の識別におけるカットオフエネルギーの分類の重要性が示された。また層が浅いモデルほど識別率が高いことから、Vela SNR の寄与はエネルギー到来方向マップの大規模な構造に現れることが分かった。層を重ねると、この大規模構造ではない、細かなデータの特徴を過剰にとらえてしまい、未知データに対する識別能力が下がるのではないかと考えた。

Vela SNR のカットオフエネルギー E_c を 10 TeV、100 TeV の 2 クラスに分類するタスクにおいて、最大で 91.2% の正解率を達成し、高い精度で分類が可能であることが確認できた。一方で、このタスクにおいて損失を最小化する中間層の数は 1 であり、非線形変換 1 回の比較的単純なモデルでの分類能力の高さを確認できた。二値分類という比較的単純かつ 10 TeV と 100 TeV のようにその違いが観測結果に顕著に表れるタスクにおいては、層が浅く、単純なモデルで十分に識別ができると考えられる。逆に、層を深くすると、学習データの細かいヒットの特徴を過剰に学習してしまい、未知データに対する適応力が低下してしまうのだと考えた。さらに単純な非線形変換なしのロジスティック回帰モデルにおける低エネルギー領域でのカットオフエネルギーの分類能力の高さを確認できた。また、この分類タスクにおいて、最もカットオフエネルギーの特徴を残すエネルギー領域は約 500 GeV 以上であることが分かった。

8.2 今後の展望

超新星残骸の兆候の識別タスクにおいては更なる精度向上のため、2030 年までの CALET の観測時間 14 年での学習を行い、より高い統計量によって識別能力の向上を図ることが必要である。加えて、超新星残骸の兆候に対する信頼度を高める目的で、偽陽性率をより低減させるために学習を非対称にし、偽陽性に対してペナルティを与えるなどの工夫も求められる。さらに、Vela SNR の兆候だけでなく、他の近傍超新星残骸の兆候の識別が可能かどうかの評価も求められる。

カットオフエネルギーの二値分類タスクにおいては、十分に分類ができることが確認できたが、より精密な分類を行うのが今後の課題である。10 TeV と 100 TeV の分類だけでなくその間の 20 TeV、50 TeV の分類も

行い、より細かい分類が可能かどうかを評価する必要がある。さらに、分類ではなく、連続的な実数値として出力・予言を行うことができるモデルの作成が求められる。また、カットオフエネルギー以外の超新星残骸のパラメータ (放出時間、遅延時間など) についても同様に分類タスクを行い、識別可能性を評価することも重要である。

さらに、本研究では数値シミュレーションによる観測サンプルにおける識別・分類可能性を評価したが、実用化に向けて実際の観測データに対しても同様に識別・分類を行い、評価する必要がある。

加えて、作成したモデルにはまだまだ改良の余地がある。完全な最適化には、モデルの構造自体や細部に至る、すべてのハイパーパラメータを走査し、評価を行う必要がある。特に、学習を行うデバイスの性能やメモリ容量の制限によって層の数やノードの数、バッチサイズや実現可能な実行時間などが制限されているため、デバイスの性能向上に期待し、より大規模なモデルの構築やより細かいパラメータの走査をできるようにすることも重要である。

最終的には、機械学習による予言の精度を 100% に近づけ、機械学習による解析をより確かなものとすることで、宇宙線の起源や伝播機構の解明をより高い精度で達成することが目標である。

9 謝辞

本研究を進めるにあたって、多くの方々から指導や助言、支援をしていただきました。ここに深く感謝申し上げます。

まず、指導教員である Motz 教授には、宇宙線ゼミでのご指導、研究方針の助言、卒業論文の助言や推薦書の執筆など、非常に多くの支援をしていただきました。また、英語力の拙い私に対しても、コミュニケーションに屈することなく丁寧にご指導いただきました。心より感謝申し上げます。同じく Motz 研究室の同期の皆様には、物理やプログラミングに関する議論などで大変お世話になりました。皆様のおかげで研究を円滑に進めることができました。Motz 研究室の元メンバーである玉置さんには、私の研究に関する助言や、院試などの研究以外の相談にも乗ってくださいました。ここに感謝申し上げます。最後に、物理に関する議論や研究以外の相談、院試期間の支えになってくれた家族や友人の皆様に心より感謝申し上げます。

この研究に関わってくださったすべての方々のこれからの活躍をお祈り申し上げます。

参考文献

- [1] Victor Franz Hess. Über Beobachtungen der durchdringenden Strahlung bei sieben Freiballonfahrten. *Physikalische Zeitschrift*, Vol. 13, pp. 1084–1091, 1912.
- [2] T. Kobayashi, Y. Komori, K. Yoshida, and J. Nishimura. The most likely sources of high - energy cosmic - ray electrons in supernova remnants. *The Astrophysical Journal*, Vol. 601, No. 1, p. 340 – 351, January 2004.
- [3] O. Adriani, Y. Akaike, K. Asano, Y. Asaoka, E. Berti, G. Bigongiari, W. R. Binns, M. Bongi, P. Brogi, A. Bruno, J. H. Buckley, N. Cannady, G. Castellini, C. Checchia, M. L. Cherry, G. Collazuol, G. A. de Nolfo, K. Ebisawa, A. W. Ficklin, H. Fuke, S. Gonzi, T. G. Guzik, T. Hams, K. Hibino, M. Ichimura, K. Ioka, W. Ishizaki, M. H. Israel, K. Kasahara, J. Kataoka, R. Kataoka, Y. Katayose, C. Kato, N. Kawanaka, Y. Kawakubo, K. Kobayashi, K. Kohri, H. S. Krawczynski, J. F. Krizmanic, P. Maestro, P. S. Marrocchesi, A. M. Messineo, J. W. Mitchell, S. Miyake, A. A. Moiseev, M. Mori, N. Mori, H. M. Motz, K. Munakata, S. Nakahira, J. Nishimura, S. Okuno, J. F. Ormes, S. Ozawa, L. Pacini, P. Papini, B. F. Rauch, S. B. Ricciarini, K. Sakai, T. Sakamoto, M. Sasaki, Y. Shimizu, A. Shiomi, P. Spillantini, F. Stolzi, S. Sugita, A. Sulaj, M. Takita, T. Tamura, T. Terasawa, S. Torii, Y. Tsunesada, Y. Uchihori, E. Vannuccini, J. P. Wefel, K. Yamaoka, S. Yanagita, A. Yoshida, K. Yoshida, and W. V. Zober. Direct measurement of the spectral structure of cosmic-ray Electrons+ Positrons in the tev region with calet on the international space station. *Phys. Rev. Lett.*, Vol. 131, p. 191001, Nov 2023.
- [4] Daniele Gaggero. *Cosmic Ray Diffusion in the Galaxy and Diffuse Gamma Emission*. Springer Theses. Springer Berlin, Heidelberg, 2012. Edition 1.
- [5] 早稲田大学理工学術院総合研究所. CALET - カロリメータ型宇宙電子線望遠鏡. <https://calet.jp/id15/>, 2026. Accessed: 2026-01-25.
- [6] Tae Niita, Shoji Torii, Yosui Akaike, Yoichi Asaoka, Katsuaki Kasahara, Shunsuke Ozawa, and Tadahisa Tamura. Energy calibration of calorimetric electron telescope (calet) in space. *Advances in Space Research*, Vol. 55, No. 11, pp. 2500–2508, 2015.
- [7] 玉置功. TeV 領域における電子宇宙線のエネルギースペクトルと異方性を用いた近傍超新星残骸からの寄与検出に関する体系的予測. 卒業論文, 早稲田大学 先進理工学部 物理学科, 2025.
- [8] D. J. Bird, et al. The cosmic-ray energy spectrum observed by the Fly’s Eye. *The Astrophysical Journal*, Vol. 424, pp. 491–502, 1994.
- [9] Todor Stanev. *High Energy Cosmic Rays*. Astrophysics and Space Science Library. Springer Nature Switzerland AG, 3 edition, 2021.
- [10] Holger Motz, Yoichi Asaoka, S. Torii, and Saptashwa Bhattacharyya. Searching for Anisotropy in Electron+Positron Cosmic Rays with CALET. *PoS*, Vol. ICRC2017, p. 265, 2017.
- [11] Holger Motz, O. Adriani, Y. Akaike, K. Asano, Y. Asaoka, E. Berti, G. Bigongiari, W.R. Binns, M. Bongi, P. Brogi, A. Bruno, J.H. Buckley, N. Cannady, G. Castellini, C. Checchia, M.L. Cherry, G. Collazuol, K. Ebisawa, A.W. Ficklin, H. Fuke, S. Gonzi, T.G. Guzik, T. Hams, K. Hibino, M. Ichimura, K. Ioka, W. Ishizaki, M.H. Israel, K. Kasahara, J. Kataoka, R. Kataoka, Y. Katayose, C. Kato, N. Kawanaka, Y. Kawakubo, K. Kobayashi, K. Kohri, Henric Krawczynski, John Krizmanic, Jason Link, P. Maestro, P.S. Marrocchesi, A.M. Messineo, J.W. Mitchell, S. Miyake, A.A.

- Moiseev, M. Mori, N. Mori, K. Munakata, S. Nakahira, J. Nishimura, G. A. de Nolfo, S. Okuno, J.F. Ormes, N. Ospina, S. Ozawa, L. Pacini, P. Papini, B.F. Rauch, S.B. Ricciarini, K. Sakai, T. Sakamoto, M. Sasaki, Y. Shimizu, A. Shiomi, P. Spillantini, F. Stolzi, S. Sugita, A. Sulaj, M. Takita, T. Tamura, T. Terasawa, S. Torii, Y. Tsunesada, Y. Uchihori, E. Vannuccini, J.P. Wefel, K. Yamaoka, S. Yanagita, A. Yoshida, K. Yoshida, and W.V. Zober. Investigating the Vela SNR's Emission of Electron Cosmic Rays with CALET at the International Space Station. *PoS*, Vol. ICRC2021, p. 100, 2021.
- [12] Holger Motz, O. Adriani, Y. Akaike, K. Asano, Y. Asaoka, E. Berti, P. Betti, G. Bigongiari, W.R. Binns, M. Bongi, P. Brogi, A. Bruno, N. Cannady, G. Castellini, C. Checchia, M.L. Cherry, G. Collazuol, K. Ebisawa, A.W. Ficklin, H. Fuke, S. Gonzi, T.G. Guzik, T. Hams, K. Hibino, M. Ichimura, M.H. Israel, K. Kasahara, J. Kataoka, R. Kataoka, Y. Katayose, C. Kato, N. Kawanaka, Y. Kawakubo, K. Kobayashi, K. Kohri, H.S. Krawczynski, J.F. Krizmanic, P. Maestro, P.S. Marrocchesi, M. Mattiazzi, A.M. Messineo, J.W. Mitchell, S. Miyake, A.A. Moiseev, M. Mori, N. Mori, K. Munakata, S. Nakahira, M. Negro, G.A. de Nolfo, J. Nishimura, S. Okuno, J.F. Ormes, S. Ozawa, L. Pacini, P. Papini, B.F. Rauch, S.B. Ricciarini, K. Sakai, T. Sakamoto, M. Sasaki, Y. Shimizu, A. Shiomi, P. Spillantini, F. Stolzi, S. Sugita, A. Sulaj, M. Takita, T. Tamura, T. Terasawa, S. Torii, Y. Tsunesada, Y. Uchihori, E. Vannuccini, J.P. Wefel, K. Yamaoka, S. Yanagita, A. Yoshida, K. Yoshida, and W.V. Zober. CALET's sensitivity to electron cosmic-ray spectral and anisotropy signatures of the Vela SNR. *PoS*, Vol. ICRC2025, p. 099, 2025.
- [13] Holger Motz. A Cosmic-Ray Propagation Model based on Measured Nuclei Spectra. *PoS*, Vol. ICRC2023, p. 068, 2023.

A 機械学習で用いた関数

sparse_plus 関数

sparse_plus 関数は、活性化関数の一つである。入力 x に対して以下のように定義される。

$$f(x) = \begin{cases} 0 & (x \leq -1) \\ \frac{1}{4}(x+1)^2 & (-1 < x < 1) \\ x & (1 \leq x) \end{cases} \quad (\text{A.1})$$

sparse_plus 関数は、入力が-1 以下の場合に 0 を出力し、-1 から 1 の範囲では二次関数的に変化し、1 以上では恒等関数となる。sparse_plus 関数は ReLU 関数よりも滑らかな接続をし、負の値を抑制しつつ、正の値をそのまま通過させることができる。これにより、ニューラルネットワークの学習において、スパースな表現を促進し、背景ノイズの影響を軽減する効果がある。

softmax 関数

softmax 関数は、主に多クラス分類問題における出力層で用いられる活性化関数である。入力ベクトル $\mathbf{z} = (z_1, z_2, \dots, z_K)$ に対して、各要素 z_i を以下のように変換する。

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (\text{A.2})$$

softmax 関数は、入力ベクトルの各要素を指数関数で変換し、その和で割ることで、出力ベクトルの各要素が 0 から 1 の範囲に正規化され、全体の和が 1 になるように規格化する。これにより、出力ベクトルは確率分布として解釈できる。

シグモイド関数

シグモイド関数は、主に二値分類問題における出力層で用いられる活性化関数である。入力 x に対して以下のように定義される。

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (\text{A.3})$$

シグモイド関数は、入力値を 0 から 1 の範囲に正規化する。入力が大きな正の値の場合、出力は 1 に近づき、入力が大きな負の値の場合、出力は 0 に近づく。この特性により、シグモイド関数は二値分類問題での出力に適している。

カテゴリカルクロスエントロピー

カテゴリカルクロスエントロピーは、多クラス分類問題によく使用される損失関数である。正解ラベルがワンホットエンコーディング形式で与えられる場合に使用される。出力ベクトル $\mathbf{p} = (p_1, p_2, \dots, p_K)$ と正解ラベルベクトル $\mathbf{q} = (q_1, q_2, \dots, q_K)$ に対して、カテゴリカルクロスエントロピー損失 L は以下のように定義される。

$$L = - \sum_{i=1}^K q_i \log(p_i) \quad (\text{A.4})$$

ここで、 K はクラス数、 p_i はクラス i の予測確率、 q_i はクラス i の正解ラベル (1 または 0) である。カテゴリカルクロスエントロピーは、予測確率が正解ラベルに近いほど小さくなり、予測が外れるほど大きくなる。

二値交差エントロピー

二値交差エントロピーは、二値分類問題によく使用される損失関数である。出力 p と正解ラベル q に対して、二値交差エントロピー損失 L は以下のように定義される。

$$L = -[q \log(p) + (1 - q) \log(1 - p)] \quad (\text{A.5})$$

ここで、 p はクラス 1 の予測確率、 q はクラス 1 の正解ラベル (1 または 0) である。二値交差エントロピーは、予測確率が正解ラベルに近いほど小さくなり、予測が外れるほど大きくなる。二値分類における softmax 関数とカテゴリカルクロスエントロピーの組み合わせは、シグモイド関数と二値交差エントロピーの組み合わせと同等である。

卒業論文概要書

Graduation Thesis Summary

Date of submission: 1 / 26 / 2026 (MM/DD/YYYY)

所属学科 Department	物理学科	氏名 Name	平本 亮	学籍番号 Student ID number	1Y22A050-1
研究題目 Title	機械学習を用いた宇宙線電子スペクトルにおける近傍超新星残骸の兆候の識別および分類			指導教員 Advisor	Holger Martin Motz

1. 研究背景・目的

TeV 領域の宇宙線電子は、伝播中の激しいエネルギー損失から、その起源が近傍の超新星残骸 (SNR) であると考えられている。近傍 SNR の兆候は、宇宙線電子スペクトルにおける TeV 領域での再硬化や、フラックスの偏り (異方性) に現れると考えられている。スペクトルの解析では再硬化のようなものが見えているが、TeV 領域の宇宙線電子の観測の少なさから確定的な寄与の発見には至っていない。したがって、フィッティングではない、観測データへの直接的な解析法が近傍 SNR の兆候に感度があると考えられる。

そこで、機械学習によるアプローチで超新 SNR の兆候をとらえることを試みる。本研究では高エネルギー領域を含んだ宇宙線電子のヒットデータから、直接的に寄与の識別および分類が、機械学習によって可能であるかどうかの評価を行った。

2. 観測サンプルと学習モデルの作成

まず宇宙線伝播を計算できる DRAGON コードによる数値計算で宇宙線電子のフラックスを求める。これを観測データにフィッティングすることによって地球での理論的な宇宙線電子スペクトルを得られる。これと異方性の計算や CALET を想定した観測の条件 (観測時間など) に基づいた MC シミュレーションで観測サンプルを作成することができる。これを入力データとして機械学習を行う。現在までの 8 年と 2030 年までの 14 年の観測を想定したサンプルを使用し、二つのタスクを行う機械学習モデルをそれぞれ作成する。

一つ目は、高エネルギー領域のエネルギーデータを入力データとして、Vela SNR におけるカットオフエネルギーを 10TeV および 100TeV の 2 値で分類するタスクである。このタスクでは、ヒットデータのうち、最も大きい数千個のエネルギーデータを入力として、全結合層によるネットワークを作成してカットオフエネルギーの分類をさせる。

二つ目は、エネルギーとその到来方向の情報から、超新星残骸がないときのヒットデータと寄与が強い Vela SNR のみを想定したヒットデータの特徴を見分け、この二つのパターンを識別するタスクである。このタスクでは、ヒットデータから

エネルギーと到来方向の全天マップを作成し、これを二次元画像データとして入力した畳み込みニューラルネットワークを使った画像認識を行う。




図1 カットオフが 10TeV (左図) と 100TeV (右図) のときのフィッティング結果。タスク 1 ではこの二つのケースを見分ける。

3. 機械学習の結果

学習では複数パラメータを逐次変えながら走査し、学習結果の評価を示す損失が最も小さく、未知のテストデータに対する正解率が最も高くなるパラメータを探索する。

一つ目のタスクでは、中間層が 1 個のみの全結合層で、かつエネルギーが最も大きい 3000 個のデータを使用することで、その正解率は 91.2% まで達成した。

二つ目のタスクでは、畳み込み層が 1 個だけ重なった単純なモデルで、さらにエネルギーは数百 GeV 以上のデータのみ絞ることで学習を最適化し、その正解率は 85.7% まで達成した。

4. 結論と今後の展望

両タスクにおいて、寄与の識別や分類は機械学習によってある程度高い精度で可能であることが分かった。また、数百 GeV 以上のエネルギーデータに高い識別可能性があることが分かった。また、どちらのタスクにおいても、比較的単純なモデルのほうがその識別可能性が高いことも分かった。

今後は、さらなるパラメータの走査とモデルの改良によってさらなる最適化を目指すこと、さらなる長い観測での識別能力や他の近傍超新星残骸の寄与の識別可能性の評価も必要である。カットオフ以外の特徴の分類可能性や実際のデータで利用できるかの検証、カットオフの連続的な値での予測なども求められる。